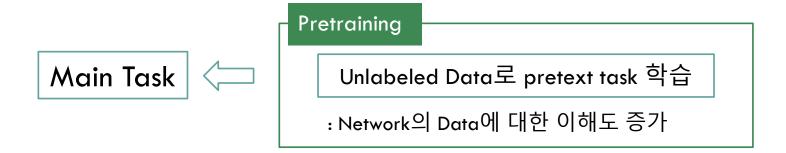
CURIOSITY-DRIVEN EXPLORATION BY SELF-SUPERVISED PREDICTION

D. Pathak et al. (2017)

BACKGROUND SELF-SUPERVISED LEARNING

Pretext task : Network의 Data 이해도를 높이기 위해 설정한 문제



Self-Supervised Learning의 목표 : Feature Extraction!

SPARSE REWARD PROBLEM - IN REAL-WORLD

Atari Breakout

: Dense Reward



Real-World Scenarios

: Extremely Sparse Rewards

Sparse Reward Problem

- Real world scenario 에서는 reward가 sparse한 경우가 많음
- 많은 경우, 확실한 action에 대해서만 reward를 주기 때문에 sparse



Random Exploration에서 reward를 얻기 쉽지 않음

효율적인 Exploration Policy 필요!

INTRINSIC REWARD

Intrinsic ~ 내재적



사람은 reward가 없어도 '호기심'이라는 내재적인 동기가 Exploration 유도

- Ryan et al. (2000), Silvia (2012)

RL에도 agent의 intrinsic reward 도입하려 시도 해왔음

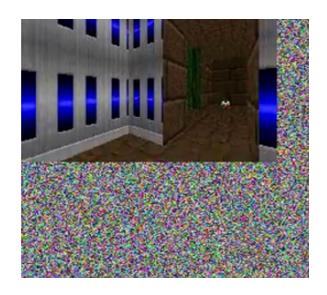
- 1. State Novelty Bellemare et al. (2016), Lopes et al. (2012), Poupart et al. (2006)
 - 방문횟수 적은 State를 방문하도록 유도
- 2. Prediction Error Houthooft et al. (2016), Mohemed & Rezende (2015) and more ...
 - Action에 의한 State의 변화에 대해 prediction error 최소화

$$r_{intrinsic} = ||\hat{s}_{t+1} - s_{t+1}||$$

두 방식 모두 새로운 Observation을 incentivize

Difficulties

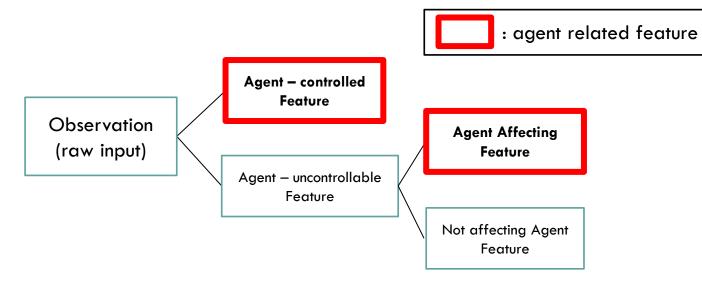
- High Dimensional Observation 다루기 힘듦
- Environment Dynamics의 Stochasticity에 영향 받음



- Every state is Novel
- Impossible to reduce Prediction Error



Agent에게 유의미한 Feature만 Predict 하자!



논문의 Key Idea

$$\phi(S) := state S \supseteq |$$
 Agent-Related Feature Vector

Feature Extraction?: Self-Supervised Learning!

Also helps **Generalization!**

INTRO SUMMARY- KEY IDEAS OF PAPER

$$r_t = r_t^i + r_t^e rac{r^i:}{r^e:}$$
 extrinsic reward

$$igg|r_t^i := rac{\eta}{2} \left| |\hat{\phi}(s_{t+1}) - \phi(s_{t+1})|
ight|_2^2$$



Agent-related Feature $\phi(s)$ 만 Predict!

Feature Prediction

Forward Model f with parameter $heta_F$;

$$\hat{\phi}(s_{t+1}) = f(\phi(s_t), a_t; heta_F)$$

$$egin{aligned} \hat{\phi}(s_{t+1}) &= f(\phi(s_t), a_t; heta_F) \ L_F\Big(\phi(s_{t+1}), \hat{\phi}(s_{t+1})\Big) &= rac{1}{2} \left| |\hat{\phi}(s_{t+1}) - \phi(s_{t+1})|
ight|_2^2 \end{aligned}$$

Feature Extraction

- Self-Supervised Learning
- Pretext task : S_t , S_{t+1} 에서 a_t 추론



일반적인 agent-related feature extraction 방법론 제안!

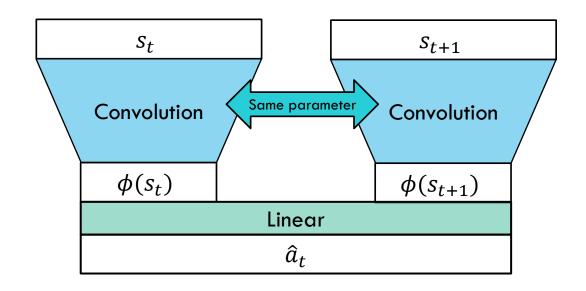
FEATURE EXTRACTION WITH SELF-SUPERVISION

Pretext task : S_t , S_{t+1} 에서 a_t 추론

Inverse Dynamics Model g with parameter $heta_I$;

$$\hat{a}_t = g(s_t, s_{t+1}; \theta_I)$$

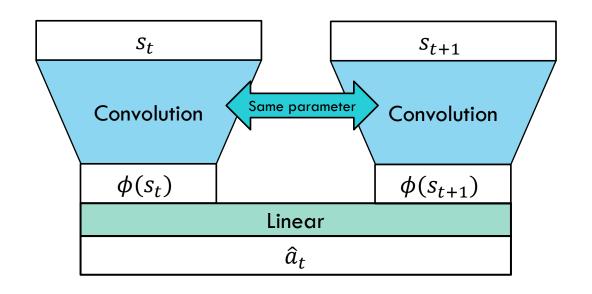
$$\min_{ heta_I} L_I(\hat{a}_t, a_t)$$

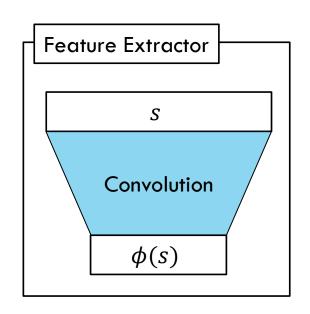


Convolution Layer : raw observation에서 feature extract

Linear Layer (Fully Connected Layer) : extract된 feature로 각 action에 대한 logit estimate

FEATURE EXTRACTION WITH SELF-SUPERVISION



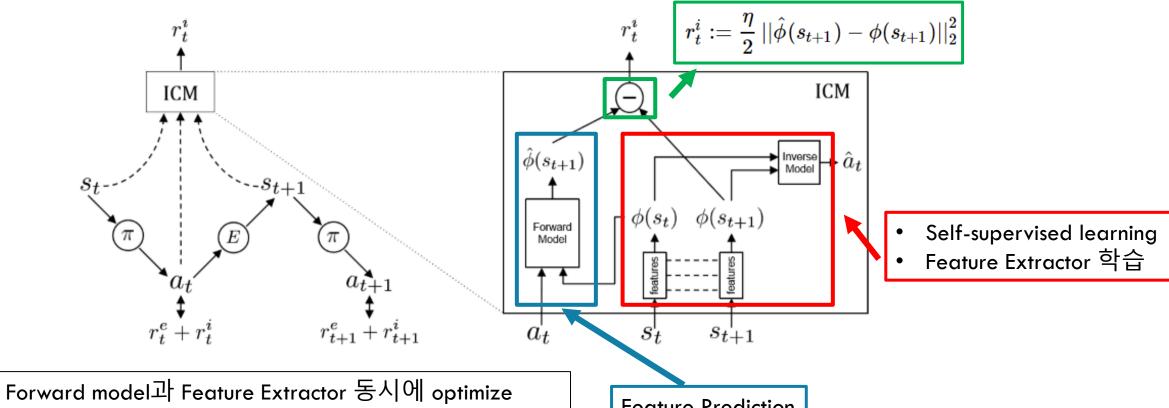


 s_t, s_{t+1} 에서 a_t 를 잘 추측하기 위해 Network가 action과 관계 있는 feature를 학습!



pretext task를 해결함으로써 feature extraction 가능

INTRINSIC CURIOSITY MODULE (ICM)



Intrinsic reward (curiosity)에 의해 Policy가 forward

model이 예측 못하는 (s, a)를 방문하도록 incentivize

Feature Prediction

OVERALL OPTIMIZATION PROBLEM

- λ: Policy gradient loss 가중치
- eta : Forward Model과 Inverse Model Loss 가중치

실험에서는 $\lambda = 0.1$, $\beta = 0.2$ 사용

Agent의 Environment에 대한 정보 습득 이미 잘 아는 (s, a)에 대해 curiosity 줄임

$$\min_{ heta_P, heta_I, heta_F} \Bigl[-\lambda \mathbb{E}_{\pi(s_t; heta_P)}[\Sigma_t r_t] + (1-eta) L_I + eta L_F \Bigr]$$

Policy는 Intrinsic Reward (curiosity) maximize

→ 새로운 state explore하도록 Policy 학습

Agent-related Feature 더욱 잘 추출하도록 학습



EXPERIMENTS

ICM의 효과

- 1. Sparse Reward Problem에 도움
 - Environment에서 reward가 없어도 학습을 지속할 수 있도록 함
- 2. Agent가 효율적인 Exploration Policy를 학습하도록 유도
 - Agent가 Environment에 대한 새로운 지식을 습득하도록 유도
- 3. Generalization에 도움

논문에서 ICM의 세가지 효과를 실험적으로 증명해 냄

THREE EXPERIMENTS

- 1. Sparse Extrinsic Reward Setting
- No Extrinsic Reward Setting (Only Intrinsic Rewards)
- 3. Generalization

Used Environments

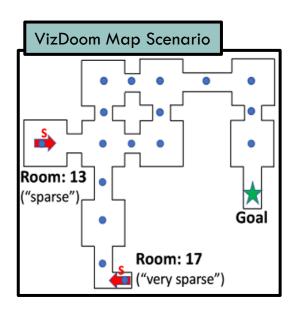
- OpenAl gym DoomMyWayHome-v0 (VizDoom)
- 2. Super Mario Bros.

Used Agents

- 1. A3C with ε -greedy exploration
- 2. ICM + A3C
- 3. ICM-pixels*+ A3C

^{*} ICM-pixels : feature 이용하지 않고 raw input으로 intrinsic reward 생성

SPARSE REWARD SETTINGS - EXPERIMENT SETUP



Reward Settings

- "Dense" reward : 파란 점에서 시작
- "Sparse" reward : 13번 방에서 시작
 - Optimal Policy 기준 goal 까지 **270 step**
- "Very-Sparse" reward : 17번 방에서 시작
 - Optimal Policy 기준 goal 까지 **350 step**

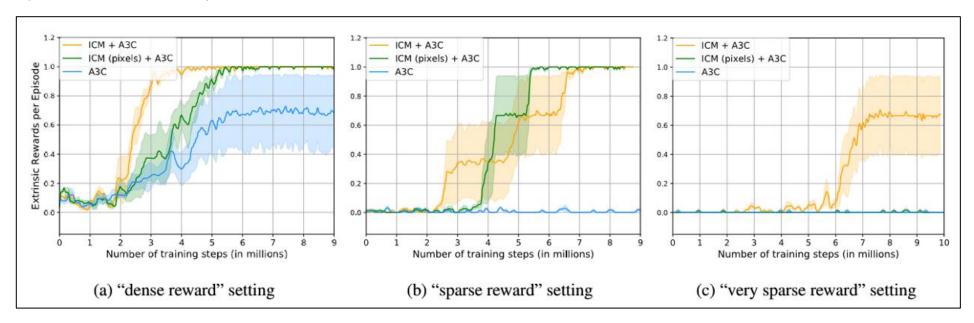
Environment Setting

$$r_t^e = egin{cases} 1 & ext{if } s_{t+1} ext{is goal state} \ 0 & ext{else} \end{cases}$$

goal state에 도달하거나 2100 step 후 episode 종료

SPARSE REWARD SETTINGS - EXPERIMENT RESULT

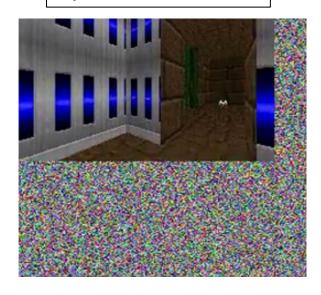
 $(mean \pm standard error)$



- Curious agent가 ε -greedy exploration 보다 잘 학습함
- "Very Sparse" Reward setting에서는 ICM+A3C만 학습 성공

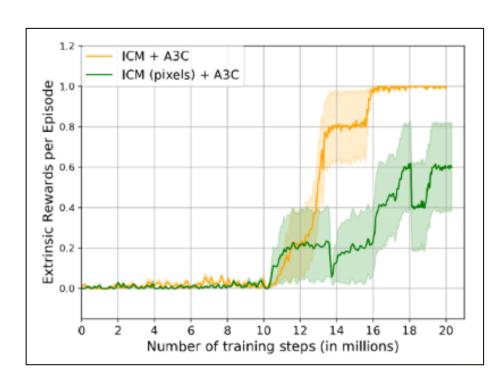
SPARSE REWARD SETTINGS - ROBUSTNESS OF ICM

Input with white noise





"Sparse" reward setting





ICM은 Agent와 무관한 feature에 robust함!

SPARSE REWARD SETTINGS - COMPARISON TO TRPO-VIME

VIME: 2017년 당시 state-of-the-art exploration method

TRPO: A3C보다 Sample Efficient한 method

Method	Mean (Median) Score				
("sparse" reward setup)	(at convergence)				
TRPO	26.0 % (0.0 %)				
A3C	0.0 % (0.0 %)				
VIME + TRPO	46.1 % (27.1 %)				
ICM + A3C	100.0 % (100.0 %)				

Sparse reward setting에서 ICM이 기능을 한 것 맞는가?



 $ightharpoonup r^i$ 대신 random noise(uniform, gaussian, laplacian)로 실험



전부 goal 도달 못함

NO REWARD SETTINGS - EXPERIMENT SETUP

Good Exploration Policy ≈ Visit as many states as possible without goals



각 환경에서 extrinsic reward 없이 agent가 방문하는 state 수 비교 (comparison to random exploration)

VizDoom

- 2100 step 이후 종료
- 전체 방 중 방문한 방의 비율 비교

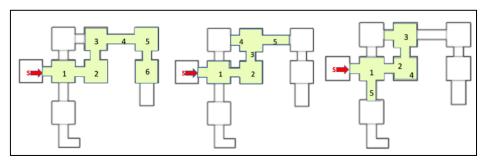
Mario

- extrinsic reward 없이 맵 진행률

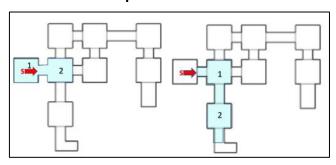
NO REWARD SETTINGS - RESULTS

Exploration Patterns in VizDoom

ICM



Random Exploration



→ External reward 없이 useful한 exploration policy 학습

Mario

- 외부 보상 전혀 없이 Level-1의 30%가량 진척 성공
- 적을 죽이거나, 도망가는 방법 스스로 학습



죽지않고 계속 progress하는 것이 Curiosity를 더욱 키우기 때문

GENERALIZATION - EXPERIMENT SETUP

Agent가 generalized skill을 습득하는 것인지, 단지 training set을 memorize하는 것인지 확인

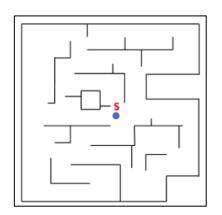
Curiosity 만으로 Pre-train한 policy를 3가지 방법으로 적용

- "as is": pre-trained policy 그대로 적용한 결과
- Fine-tuning with / without extrinsic rewards

Mario

Level-1에서 Intrinsic Reward 만으로 pre-train 이후 Level-2, 3에 적용

(as is , Fine-tuning with curiosity)



VizDoom

Train map에서 pre-train 후 "Very Sparse" setting에서 evaluate

Train map for VizDoom

GENERALIZATION - MARIO

Level Ids	Level-1	1 Level-2				Level-3			
Accuracy Iterations	Scratch 1.5M	Run as is	Fine-tuned 1.5M	Scratch 1.5M	Scratch 3.5M	Run as is	Fine-tuned 1.5M	Scratch 1.5M	Scratch 5.0M
Mean ± stderr % distance > 200 % distance > 400 % distance > 600	$711 \pm 59.3 \\ 50.0 \pm 0.0 \\ 35.0 \pm 4.1 \\ 35.8 \pm 4.5$	31.9 ± 4.2 0 0 0	466 ± 37.9 64.2 ± 5.6 63.6 ± 6.6 42.6 ± 6.1	399.7 ± 22.5 88.2 ± 3.3 33.2 ± 7.1 14.9 ± 4.4	$455.5 \pm 33.4 \\ 69.6 \pm 5.7 \\ 51.9 \pm 5.7 \\ 28.1 \pm 5.4$	319.3 ± 9.7 50.0 ± 0.0 8.4 ± 2.8 0	97.5 ± 17.4 1.5 ± 1.4 0 0	11.8 ± 3.3 0 0 0	42.2 ± 6.4 0 0 0

As is

Level-3는 texture가 비슷해서 매우 잘됨 Level-2는 texture 많이 다름 (night world)



Fine-tuning

Level-2 : Fine tuning한 결과 texture 달라도 일반화 성공 많은 iteration으로 처음부터 학습시킨 agent보다 성능 좋음

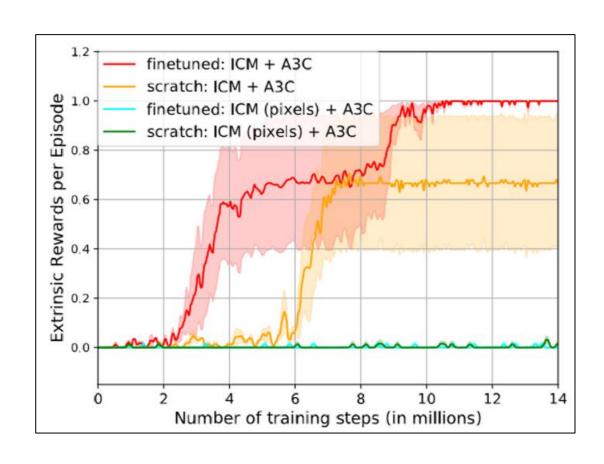
Level-3에서 fine-tune 결과 성능 퇴화



Level-3에 curiosity만으로는 넘어가기 힘든 어려운 구간 존재이 구간을 넘어가지 못하면서 curiosity 0에 수렴 (boredom)

GENERALIZATION - VIZDOOM

Pretrain 후 새로운 map과 texture로 generalization 되었는지 실험



- ICM-pixel은 전혀 성공 못함
- Pre-train된 ICM+A3C agent가 더 빨리 학습
 - → generalizable한 exploring policy를 학습하였음

SUMMARY

1. ICM architecture를 도입, curiosity-driven intrinsic reward를 생성
Sparse reward problem 해결, 좋은 exploration policy 학습 가능

Generalization

Self-supervised Learning을 이용한 Feature Extractor로 agent-related feature만 extract 할 수 있었음 실험적으로 generalization이 잘 되었음을 입증

REFERENCE

- D. Pathak et al. (2017) Curiosity-driven Exploration by Self-supervised Prediction.
- 이호성 (2019) Unsupervised Visual Representation Learning Overview : Toward Self-Supervision. Retrieved from https://hoya012.github.io/blog/Self-Supervised-Learning-Overview/
- 박건영 (n.d.) Curiosity-driven Exploration 리뷰. Retrieved from https://parkgeonyeong.github.io/Curiosity-driven-Exploration-%EB%A6%AC%EB%B7%B0/