(ICML) 2017

A Distributional Perspective on Reinforcement Learning

Marc G. Bellemare * 1 Will Dabney * 1 Rémi Munos 1




Marc G. Bellemare

Google Brain google.com의 이메일 확인됨 - <u>홈페이지</u> Reinforcement Learning Information Theory



제목	인용	연도
Human-level control through deep reinforcement learning V Mnih, K Kavukcuoglu, D Silver, AA Rusu, J Veness, MG Bellemare, nature 518 (7540), 529-533	12534	2015
The Arcade Learning Environment: An Evaluation Platform for General Agents MG Bellemare, Y Naddaf, J Veness, M Bowling Journal of Artificial Intelligence Research 47, 253279	1641	2013
Unifying count-based exploration and intrinsic motivation M Bellemare, S Srinivasan, G Ostrovski, T Schaul, D Saxton, R Munos Advances in neural information processing systems 29, 1471-1479	664	2016
A distributional perspective on reinforcement learning MG Bellemare, W Dabney, R Munos arXiv preprint arXiv:1707.06887	510	2017

Motivation



Breaks down once a week (5일에 한번 delay)

(3x5) + 15 / 5 = 18 min.

미래 보상들은 complex, Multimodal의 특성을 가지는 데,

기대값은 각 보상들이 가지는 특성을 담아내지 못한다. → 평균 하지말고 case마다의 시간 계산하자

Part 02

BackGround

[논문 요약]

- \checkmark 시간 t에서 Discount Factor(γ)가 적용된 보상 $r_t = \sum_{tr=t}^{T} \gamma^{t'-t} r_{tr}$ (T는 게임의 종료 시점) ex) $r_3 = r_3 + \gamma^1 r_4 + \gamma^2 r_5 + \gamma^3 r_6 + \dots + \gamma^{T-3} r_T$
- \checkmark 새로 정의한 action-value function $Q^*(s,a) = \max_{\pi} E[R_t|s_t = s, a_t = a, \pi]$ $(s_t$ 는 Sequence, a는 선택한 Action) 즉, Policy π 를 통해 얻을 수 있는 Reward 의 Maximum Expected Value를 구함
- ✓ Bellman Equation에 따라 all possible action a'에 대해 next time-step에서 Optimal Q*(s,a)를 안다면 Optimal Strategy는 r + y * Q*(s,a)를 Maximize하는 것이다.
- ✓ RL은 위와 같은 Optimal Strategy를 iterative update하게 사용, $converge(Q_i \rightarrow Q^*)$ as $(i \rightarrow \infty)$

$$Q_{i+1}(s,a) = \mathbb{E}igg[r + \gamma Q_i(s',a') \ igg| \ s,aigg]$$

그러나 action-value function은 각 sequence마다 독립적으로 측정되기 때문에, 이런 방식은 실제로 impractical(비현실적) 하다. 대신 function approximator를 사용하여 action-value function을 적절히 approximate 시킨다.

$$Q(s,a; heta)\simeq Q^*(s,a).$$

일반적으로는 Linear Function으로 Approximate 하지만, 간혹 Non-Linaer Function으로 Approximate하는 경우도 있다. neural network function approximator로 weight θ 를 사용하는 것을 Q-network라고 한다. Q-Network는 each iteration마다 바뀌는 Loss function $L_i(\theta_i)$ 를 죄소화시킴으로써 학습을 한다.

$$L_i(heta_i) = \mathbb{E}_{s,a \sim
ho(\cdot)}igg[ig(y_i - Q(s,a; heta_i)ig)^2igg], ext{where, } y_i = \mathbb{E}_{s' \sim \mathcal{E}}igg[r + \gamma \max_{a'} Q(s',a'; heta_{i-1}) \mid s,aigg]$$

- ✓ But 이러한 Action-Value Function은 각 Sequence에 대해 독립적으로 estimate되므로 비현실적이다.
- \checkmark θ 를 Weight로 갖는 Non-Linear Network Function Approximator를 통해 Approximate $Q(s,a;\theta)\simeq Q^*(s,a)$.
- θ를 학습시키기 위해 i번째 iteration에서 다음과 같은 loss function을 갖게 하여 θ가 Converge 할 때 까지 반복시키고, 여기서 y_i는 iteration의 target value이다.

$$abla_{ heta_i} L_i(heta_i) = \mathbb{E}_{s,a\sim
ho(\cdot);s'\sim\mathcal{E}}igg[ig(r+\gamma\max_{a'}Q(s',a'; heta_{i-1})-Q(s,a; heta_i)ig)
abla_{ heta_i}Q(s,a; heta_i)igg]igg|$$

 \checkmark θ_{i-1} 은 $L_i(\theta_i)$ 를 optimizing 할 때 정해진다.

Key Idea

Return을 Distribution으로 만들어 Randomness한 특성과 정보를 최대한 반영해보자

Bellman Equation

(State Action Function)

$$Q(x, a) = \mathbb{E} R(x, a) + \gamma \mathbb{E} Q(X', A').$$

distributional bellman equation



$$Z(x,a) \stackrel{D}{=} R(x,a) + \gamma Z(X',A').$$

$$Q(x,a) = \mathbb{E} R(x,a) + \gamma \mathbb{E} Q(X',A').$$

기존에는 Q의 기대값을 러닝했다면, Random Return Z의 Distribution을 러닝


Action마다 Discrete Distribution with 51 values

4.1. Parametric Distribution

We will model the value distribution using a discrete distribution parametrized by $N \in \mathbb{N}$ and $V_{\text{MIN}}, V_{\text{MAX}} \in \mathbb{R}$, and whose support is the set of atoms $\{z_i = V_{\text{MIN}} + i \triangle z : 0 \le i < N\}$, $\triangle z := \frac{V_{\text{MAX}} - V_{\text{MIN}}}{N-1}$. In a sense, these atoms are the "canonical returns" of our distribution. The atom probabilities are given by a parametric model $\theta : \mathcal{X} \times \mathcal{A} \to \mathbb{R}^N$

$$Z_{\theta}(x,a) = z_i$$
 w.p. $p_i(x,a) := \frac{e^{\theta_i(x,a)}}{\sum_j e^{\theta_j(x,a)}}$.

The discrete distribution has the advantages of being highly expressive and computationally friendly (see e.g. Van den Oord et al., 2016).




Support or atom $(z_i = V_{min} + i\Delta z : 0 \le i \le N)$

N: support 의 수 V_{min}, V_{max}: support 의 최소, 최대값

 p_i : 각 support의 값을 받을 확률 $(0 \le i \le N)$ -> Network 의 output $\stackrel{\circ}{=}$ softmax

Target Value Distribution



N: support 의 수

V_{min}, V_{max}: support 의 최소, 최대값

 p_i : 각 support의 값을 받을 확률 $(0 \le i \le N)$ -> Network 의 output 을 softmax

$$Q(x_t, a_t) = \sum_i z_i p_i(x_t, a_t)$$

N: supports의 수, V_{min} : support의 최소값, Δz : support간 간격


 z_i : support $(z_i = V_{min} + i\Delta z: 0 \le i \le N)$

 p_i : support z_i 에 대한 확률


Target value distribution

- 1. 다음 state에 대한 value 분포를 구함 $Z(s',a') \longrightarrow p_i(s',a')$
- 2. Target atom을 구함 $\hat{T}z_i$


$$\hat{T}z_i = [R + \gamma z_i]_{V_{\min}}^{V_{\max}}$$




Target Value Distribution - Projection




- Target value distribution Projection
 - Target value distribution과 value distribution의 atom이 불일치
 - Target atom이 reward와 r와의 연산 때문에 변경됨
 - Projection을 통해 일치 시킴.






Cost function

Target value distribution과 현재 value distribution간의 차이를 줄이는 방향으로 학습



$$d_p(F,G) = \left(\int_0^1 |F^{-1}(u) - G^{-1}(u)|^p du \right)^{1/p}$$

Algorithm




Result

Categorical DQN

Support의 수(N)을 많이 설정할수록 더 좋은 성능을 보인다.

•51개의 support를 사용했을 때 게임에서 좋은성능을 보여 C51이라 지칭.



- •Sparse한 reward환경의 게임 (Private Eye, Venture)같은 게임에서 다른 알고리즘에 비해 좋은성능을 보임
- •기존 DQN, DDQN, Nueling, PER, PER + Dueling 과 비교 했을 때 매우 좋은 성능을 보여준다.

GAMES	RANDOM	HUMAN	DQN	DDQN	DUEL	PRIOR. DUEL.	C51
Private Eye	24.9	69,571.3	146.7	129.7	103.0	206.0	15,095
Venture	0.0	1,187.5	163.0	98.0	497.0	48.0	1,520




Figure 12. Number of Atari games where an agent's training performance is greater than a baseline (fully trained DQN & human). Error bands give standard deviations, and averages are over number of games.




Figure 4. Learned value distribution during an episode of SPACE INVADERS. Different actions are shaded different colours. Returns below 0 (which do not occur in SPACE INVADERS) are not shown here as the agent assigns virtually no probability to them.

Reference

https://www.youtube.com/watch?v=6CdV0kgyPI8&t=603s https://www.youtube.com/watch?v=fwv8iEifCFU https://kminseo.tistory.com/16