Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor

키워드

Entropy, sample complexity, stable

Abstract

Model-free deep reinforcement learning (RL) 의 난제 2개 : sample complexity와 brittle convergence properties 해결 어려움 ->액션의 차원이 높으면 높을수록 다양한 형태의 샘플이 잔뜩 필요하고, 자그만한 하이퍼 파라미터 변화에도 수렴이 잘 안되는 불안정한 현상이 보인다.

여기서 저자가 제안한 Soft Actor Critic은 maximum entropy reinforcement learning framework을 기반으로 한 off-policy actor critic deep RL을 제안하였다.

여기서 Actor는 entropy를 최대로 하는 동시에 Expected reward를 최대로 목표한다. 또 다른 이 프레임워크는 안정적이다.


엔트로피 란?

사전적 정의 (열역학): 유용하지 않은 (일로 변환할 수 없는) 에너지의 흐름을 설명할 때 이용하는 상태 함수통계적 정의 (정보 이론): 어떤 사건이 정보적 측면에서 얼마나 중요한가를 반영한 로그 지표에 대한 기댓값-> 정보량

$$H(X) = E \left[\log \frac{1}{P_i(x)} \right]$$

엔트로피가 커진다?

발생 가능확률 p에따른 정보의 양




$$H(X) = E \left[\log \frac{1}{P_i(x)} \right]$$

요약: 확률이 낮을수록, 어떤 정보일지는 불확실하게 되고, 우리는 이때 '정보가 많다', '엔트로피가 높다'고 표현한다.

Actor의 엔트로피가 최대?

$$J(\pi) = \sum_{t=0}^{T} \mathbb{E}_{(\mathbf{s}_t, \mathbf{a}_t) \sim \rho_{\pi}} \left[r(\mathbf{s}_t, \mathbf{a}_t) + \alpha \mathcal{H}(\pi(\cdot | \mathbf{s}_t)) \right].$$

발생 가능확률 p에따른 정보의 양



$$H(X) = E \left[\log \frac{1}{P_i(x)} \right]$$

요약: 확률이 낮은 action을 최대한 많이 선택한다.

→ 각 state에서 잘 선택하지 않던 action(선택할 확률이 낮은 action)도 선택함으로서 exploration 향상

Derivation of Soft Policy Iteration

$$\mathcal{T}^{\pi}Q(\mathbf{s}_t, \mathbf{a}_t) \triangleq r(\mathbf{s}_t, \mathbf{a}_t) + \gamma \mathbb{E}_{\mathbf{s}_{t+1} \sim p} \left[V(\mathbf{s}_{t+1}) \right]$$

$$\times V(\mathbf{s}_t) = \mathbb{E}_{\mathbf{a}_t \sim \pi} \left[Q(\mathbf{s}_t, \mathbf{a}_t) - \log \pi(\mathbf{a}_t | \mathbf{s}_t) \right]$$

Lemma 1 (Soft Policy Evaluation). Consider the soft Bellman backup operator \mathcal{T}^{π} in Equation 2 and a mapping $Q^0: \mathcal{S} \times \mathcal{A} \to \mathbb{R}$ with $|\mathcal{A}| < \infty$, and define $Q^{k+1} = \mathcal{T}^{\pi} Q^k$. Then the sequence Q^k will converge to the soft Q-value of π as $k \to \infty$.

Derivation of Soft Policy Iteration

$$\pi_{\text{new}} = \arg\min_{\pi' \in \Pi} D_{\text{KL}} \left(\pi'(\cdot | \mathbf{s}_t) \, \middle\| \, \frac{\exp\left(Q^{\pi_{\text{old}}}(\mathbf{s}_t, \cdot)\right)}{Z^{\pi_{\text{old}}}(\mathbf{s}_t)} \right). \tag{4}$$

Lemma 2 (Soft Policy Improvement). Let $\pi_{\text{old}} \in \Pi$ and let π_{new} be the optimizer of the minimization problem defined in Equation 4. Then $Q^{\pi_{\text{new}}}(\mathbf{s}_t, \mathbf{a}_t) \geq Q^{\pi_{\text{old}}}(\mathbf{s}_t, \mathbf{a}_t)$ for all $(\mathbf{s}_t, \mathbf{a}_t) \in \mathcal{S} \times \mathcal{A}$ with $|\mathcal{A}| < \infty$.

Derivation of Soft Policy Iteration

Theorem 1 (Soft Policy Iteration). Repeated application of soft policy evaluation and soft policy improvement from any $\pi \in \Pi$ converges to a policy π^* such that $Q^{\pi^*}(\mathbf{s}_t, \mathbf{a}_t) \geq Q^{\pi}(\mathbf{s}_t, \mathbf{a}_t)$ for all $\pi \in \Pi$ and $(\mathbf{s}_t, \mathbf{a}_t) \in \mathcal{S} \times \mathcal{A}$, assuming $|\mathcal{A}| < \infty$.

Soft Actor Critic

end for

Algorithm 1 Soft Actor-Critic Initialize parameter vectors ψ , $\bar{\psi}$, θ , ϕ . for each iteration do for each environment step do $\mathbf{a}_t \sim \pi_{\phi}(\mathbf{a}_t|\mathbf{s}_t)$ $\mathbf{s}_{t+1} \sim p(\mathbf{s}_{t+1}|\mathbf{s}_t,\mathbf{a}_t)$ $\mathcal{D} \leftarrow \mathcal{D} \cup \{(\mathbf{s}_t,\mathbf{a}_t,r(\mathbf{s}_t,\mathbf{a}_t),\mathbf{s}_{t+1})\}$ end for for each gradient step do $\psi \leftarrow \psi - \lambda_V \hat{\nabla}_{\psi} J_V(\psi)$ $\theta_i \leftarrow \theta_i - \lambda_Q \hat{\nabla}_{\theta_i} J_Q(\theta_i)$ for $i \in \{1,2\}$ $\phi \leftarrow \phi - \lambda_\pi \hat{\nabla}_{\phi} J_\pi(\phi)$ $\bar{\psi} \leftarrow \tau \psi + (1-\tau)\bar{\psi}$ end for

Soft Actor Critic

V value loss function

$$J_{V}(\psi) = \mathbb{E}_{\mathbf{s}_{t} \sim \mathcal{D}} \left[\frac{1}{2} \left(V_{\psi}(\mathbf{s}_{t}) - \mathbb{E}_{\mathbf{a}_{t} \sim \pi_{\phi}} \left[Q_{\theta}(\mathbf{s}_{t}, \mathbf{a}_{t}) - \log \pi_{\phi}(\mathbf{a}_{t} | \mathbf{s}_{t}) \right] \right)^{2} \right]$$
(5)

Q value loss function

$$J_Q(\theta) = \mathbb{E}_{(\mathbf{s}_t, \mathbf{a}_t) \sim \mathcal{D}} \left[\frac{1}{2} \left(Q_{\theta}(\mathbf{s}_t, \mathbf{a}_t) - \hat{Q}(\mathbf{s}_t, \mathbf{a}_t) \right)^2 \right], \tag{7}$$

 $\times \hat{Q}(\mathbf{s}_t, \mathbf{a}_t) = r(\mathbf{s}_t, \mathbf{a}_t) + \gamma \mathbb{E}_{\mathbf{s}_{t+1} \sim p} \left[V_{\bar{\psi}}(\mathbf{s}_{t+1}) \right],$

Soft Actor Critic


Policy loss function

$$J_{\pi}(\phi) = \mathbb{E}_{\mathbf{s}_{t} \sim \mathcal{D}} \left[D_{KL} \left(\pi_{\phi}(\cdot | \mathbf{s}_{t}) \, \middle\| \, \frac{\exp\left(Q_{\theta}(\mathbf{s}_{t}, \cdot)\right)}{Z_{\theta}(\mathbf{s}_{t})} \right) \right]. \tag{10}$$




$$J_{\pi}(\phi) = \mathbb{E}_{\mathbf{s}_{t} \sim \mathcal{D}, \epsilon_{t} \sim \mathcal{N}} \left[\log \pi_{\phi}(f_{\phi}(\epsilon_{t}; \mathbf{s}_{t}) | \mathbf{s}_{t}) - Q_{\theta}(\mathbf{s}_{t}, f_{\phi}(\epsilon_{t}; \mathbf{s}_{t})) \right],$$
(12)

Experiment




Stochastic vs deterministic policy



Stochastic은 안정적으로 expected return이 증가

Deterministic은 변동성이 너무 큰상태로 expected return 이 증가

Policy evaluation




(a) Evaluation

최종적으로 stochastic policy를 deterministic하게 해야 더 나은 성능을 보여준다.

여기서 stochastic evalution은 원래 stochastic polic의 expected return을 평가하는거고

Deterministic evalution은 그 stochastic policy distribution의 mean 값에 해당되는 action을 선택해서계산된 Expected return을 평가하는걸 의미한다.

Reward Scale




Soft Actor Critic은 reward singnal에 특히나 더 예민하다.

Reward magnitud가 크면 클수록 학습 속도가 빠를수 있지만, 이로 인해 exploration이 떨어지면서 local minima 에 빠지게 된다.

적절한 reward scale 로 조종해야 exploratio과 exploitation이 적절하게 균형이 맞추어진다.

(b) Reward Scale

Target network update



τ가 크면 training이 빠르게 진행되고, 작으면 느리게 진행된다.

(c) Target Smoothing Coefficient (τ)

감사합니다