Generalized State-Dependent Exploration (gSDE)

백승언

30 August, 2021


Contents

- Introduction
 - Exploration-Exploitation dilemma
 - Exploration strategies
- Generalized State-Dependent Exploration(gSDE)
 - Motivations
 - Backgrounds
 - gSDE
- Experiment results
- Implementation results

Introduction

Exploration-Exploitation dilemma

- Agent learns the optimal policy through exploration and exploitation
 - The agent need to gather enough information to make the best overall decisions (exploration)
 - The agent need to make the best decision given current information (exploitation)
- What is exploration and exploitation?
 - Exploration
 - Creating new knowledge
 - New way of thinking
 - Exploitation
 - Reusing the knowledge
 - Best way through experience



Exploration Strategies

Naïve approaches in conventional RL

- ϵ greedy / decaying ϵ greedy
- Count-based exploration
- Optimism in the face of uncertainty
 - Q-table을 0이 아닌 큰 값으로 초기화 시키는 전략
- Maximum entropy reinforcement learning

Complicated approaches in DRL

- Density modeling with entropy regularization
 - Gaussian policy
- Random noise / stochastic process
 - Gaussian noise
 - OU(Ornstein–Uhlenbeck) noise
- Curiosity-driven exploration
 - Random network distillation



이러한 탐험 기법들은 로봇, 자율주행 자동차와 같은 실제 시스템에 적용시 예상치 못한 문제를 일으킬 수 있음

Smoothness하고 less variance를 지니는 탐험 전략이 필요!

https://www.slideshare.net/DongMinLee32/exploration-strategies-in-reinforcement-learning-179779846 https://www.slideshare.net/YoonhoLee4/parameter-space-noise-for-exploration

Generalized State-Dependent Exploration (gSDE)


Motivations

Poor exploration in real robot according to jerky motion pattern with unstructured noise

- "When learning robotic skills with deep reinforcement learning(DeepRL), the de factor standard for exploration is to sample a noise vector ϵ_t from a Gaussian distribution independently at each time step t, and then adding it to the policy output"
- 이러한 구조화 되지 않은(unstructured) 탐험은 실제 로봇으로 실험을 할 때 불안정한 움직임을 야기할 수 있으며, 이는 poor exploration의 결과로 이어질 뿐 아니라, 모터 등의 구동계가 손상을 입을 수 있다고 서술
- 이러한 한계를 해결하기 위해 여러 연구가 수행되어 왔다고 함
 - Low pass filter, OU noise
- 저자들은 역시나 이러한 연구의 일환으로 연구되었던, SDE를 DeepRL에 맞게 일반화한 gSDE 연구를 제안
 - SDE: State-Dependent Exploration^[1]
 - gSDE: generalized State-Dependent Exploration^[2]

[1]: Rückstieß, Thomas, Martin Felder, and Jürgen Schmidhuber. "State-dependent exploration for policy gradient methods." Joint European Conference on Machine Learning and Knowledge Discovery in Databases. Springer, Berlin, Heidelberg, 2008.

[2]: https://arxiv.org/abs/2005.05719



Unstructured exploration as typically used in RL

Backgrounds

Exploration in Action or Policy Parameter Space^[3]

- Continuous action의 경우, exploration은 일반적으로 action space에서 이루어짐: $a_t = \mu(s_t; \theta_\mu) + \epsilon_t$. 이때, noise vector ϵ_t 는 특정 파라미터를 가정한, Gaussian distribution으로부터 sampling됨
- 이 탐험 전략의 경우, action space가 아닌, (policy) parameter space에서의 noise를 통해 탐험을 종용: $a_t = \mu(s_t; \theta_u + \epsilon), \ \epsilon \sim \mathcal{N}(0, \sigma^2)$
- 이는 일반적으로 consistent exploration을 달성할 수 있지만, parameter의 개수가 많아질수록 어려움이 존재

State-Dependent Exploration(SDE)

- 기존에 이용되던 step-based sampled noise를 episode-based, state-dependent exploration function ϵ 을 통해 계산된 noise로 대체한 탐험 전략: $a_t = \mu(s_t; \theta_u) + \epsilon(s_t; \theta_\epsilon), \; \theta_\epsilon \sim N(0, \sigma^2)$
- SDE의 경우 주어진 state에 대해, 동일 episode 내에서 동일한 noise를 계산하는 방식으로 안정적인 탐험을 꾀함($heta_\epsilon$ 을 episode 마다 sampling하는 방식 이용)
- 이는 episode 내에서 smooth하고 less variance한 탐험을 할 수 있는 결과를 만들어 냈다고 함

[3] Rückstiess, T., Sehnke, F., Schaul, T., Wierstra, D., Sun, Y., & Schmidhuber, J. (2010). Exploring parameter space in reinforcement learning. Paladyn, 1(1), 14-24.

gSDE (I)

Limitation of original SDE

- "The noise does not change during one episode, which is problematic if the episode is long, because the exploration will be limited"
- "The variance of policy depends on the state dimension(it grows with it), which means that the initial σ must be tuned for each problem"
 - In SDE, $\pi_j(a_j \mid s) \sim \mathcal{N}(\mu_j(s), \ \hat{\sigma}_j^2), \ \hat{\sigma}_j = \sqrt{\Sigma_i(\sigma_{ij} \mathbf{s_i})^2}$
- "There is only a linear dependency between the state and the exploration noise, which limits the possibilities."
 - In SDE, $a_t = \mu(s_t; \theta_{\mu}) + \epsilon(s_t; \theta_{\epsilon}), \ \epsilon = \theta_{\epsilon}s$
- The state must be normalized, as the gradient and the noise magnitude depend on the state magnitude

gSDE (II)

- The Authors proposed two improvements to mitigate the mentioned issues and adapt it to DeepRL algorithms
 - Sampling the parameters θ_{ϵ} of the exploration function every n steps instead of every episode
 - Long episode, infinite horizon 문제 등에서 한계가 있었던 SDE의 첫 번째 이슈를 해결
 - Using policy features $z_{\mu}(s; \theta_{z_{\mu}})$ instead of state s as input to the noise function $\epsilon(s; \theta_{\epsilon}) = \theta_{\epsilon} z_{\mu}(s)$
 - 이때, policy feature z_{μ} 는 action $\mu(s)=\theta_{\mu}z_{\mu}(s;\theta_{z_{\mu}})$ 의 마지막 layer의 output을 의미
 - Variance of policy가 state의 차원과 관계 없이, policy network architecture에만 의존함을 의미 (두 번째 이슈 해결)
 - Exploration noise e와 s가 non linear한 관계를 가질 수 있어서 선형 관계만을 가지던 SDE에 비해 표현력 증가 (세 번째 이슈 해결)
 - 학습의 안정화를 위해 SDE에서 수행했던, state normalization등의 추가 엔지니어링이 요구되지 않음 (네 번째 이슈 해결)
 - 저자들은 이러한 개선을 수행한 결과를 generalized State-Dependent Exploration (gSDE)라고 명명

gSDE (III)

- Pseudo code(Base algorithm: SAC)
 - Algorithm parameter 초기화 (SAC의 경우, $\theta_{\mu}, \theta_{Q}, \alpha$) 및 noise parameter σ 를 초기화
 - 알고리즘이 experience memory사용시 replay buffer 초기화 (Ɗ)
 - 매 Episode가 시작될 때 마다, exploration noise parameter θ_{ϵ} 을 sampling
 - Pseudo code에 명시되어 있지는 않지만, every n step 마다 θ_{ϵ} 을 추가적으로 sampling
 - 매 step 별로 a_t 에 exploration noise $\epsilon(s_t; \theta_\epsilon)$ 을 추가하여 탐험을 종용
 - Update가 될 때마다, reparameterization trick을 통해 σ 를 학습시키기 위해 θ_{ρ} 를 sampling
 - Actor update를 통해 policy $\mu(s)$ 와 noise variance σ 를 업데이트

```
Algorithm 1 Soft Actor-Critic with gSDE
   Initialize parameters \theta_{\mu}, \theta_{Q}, \sigma, \alpha
   Initialize replay buffer \mathcal{D}
   for each iteration do
         \theta_{\epsilon} \sim \mathcal{N}(0, \sigma^2)

    Sample noise function parameters

         for each environment step do
              \mathbf{a}_t = \pi(\mathbf{s}_t) = \mu(\mathbf{s}_t; \theta_{\mu}) + \epsilon(\mathbf{s}_t; \theta_{\epsilon})
                                                                                                                   \mathbf{s}_{t+1} \sim p(\mathbf{s}_{t+1}|\mathbf{s}_t,\mathbf{a}_t)

    Step in the environment

              \mathcal{D} \leftarrow \mathcal{D} \cup \{(\mathbf{s}_t, \mathbf{a}_t, r(\mathbf{s}_t, \mathbf{a}_t), \mathbf{s}_{t+1})\}

    □ Update the replay buffer

         end for
         for each gradient step do
              \theta_{\epsilon} \sim \mathcal{N}(0, \sigma^2)

    Sample noise function parameters

              Sample a minibatch from the replay buffer \mathcal{D}
              Update the entropy temperature \alpha
              Update parameters using \nabla J_Q and \nabla J_{\pi} \triangleright Update actor \mu, critic Q and noise variance \sigma
              Update target networks
         end for
   end for
```

Pseudo code of gSDE

Experiment Results

Experiment results (I)

Comparison with different strategies for exploration

 논문에서 제시한 gSDE 기법과, 기존에 사용되던 탐험 전략들에 따른 성능을 Pybullet 환경의 여러 문제에서 비교하는 실험을 수행(Half cheetah 등에서 10번, 1M step 만큼 학습 수행)

• no exploration noise : 행동에 탐험을 위한 추가적인 noise를 주지 않음

• Unstructured gaussian noise : 기존에 널리 사용되던, $a_t = \mu(s) + \epsilon, \epsilon \sim \mathcal{N}(0, \sigma^2 I)$ 를 이용

• OU noise : 비교적 correlated variable을 sampling할 수 있는 stochastic process를 이용


• parameter space noise : action이 아닌, policy parameter에 noise를 가함 $\pi(s|a;\theta)$, $\theta \sim \mathcal{N}(\phi, \Sigma)$

• 각 기법들을 비교할 성능 지표로는, Return과 training 중의 continuity cost C_{train} 를 선택

• $C_{tarin}=100 imes \mathbb{E}_t \left[rac{a_{t+1}-a_t}{\Delta a_{max}}
ight]$ (현재 행동과 다음 행동의 차이가 얼마나 큰지 측정하는 지표)

Algorithm	HALFCHEETAH		ANT		HOPPER		WALKER2D	
SAC	Return †	$\mathcal{C}_{\mathrm{train}}\downarrow$	Return ↑	$\mathcal{C}_{\mathrm{train}} \downarrow$	Return †	$C_{\mathrm{train}} \downarrow$	Return †	$\mathcal{C}_{\mathrm{train}}\downarrow$
w/o noise	2562 +/- 102	2.6 +/- 0.1	2600 +/- 364	20 +/- 0.2	1661 +/- 270	1.8 +/- 0.1	2216 +/- 40	1.8 +/- 0.
w/ unstructured	2994 +/- 89	4.8 +/- 0.2	3394 +/- 64	5.1 +/- 0.1	2434 +/- 190	3.6 +/- 0.1	2225 +/- 35	3.6 +/- 0.
w/ OU noise	2692 +/- 68	2.9 +/- 0.1	2849 +/- 267	2.3 +/- 0.0	2200 +/- 53	2.1 +/- 0.1	2089 +/- 25	2.0 +/- 0.
w/ param noise	2834 +/- 54	2.9 +/- 0.1	3294 +/- 55	21 +/- 0.1	1685 +/- 279	2.2 +/- 0.1	2294 +/- 40	1.8 +/- 0.
w/gSDE-8	2850 +/- 73	4.1 +/- 0.2	3160 +/- 184	3.9 +/- 0.2	2646 +/- 45	2.4 +/- 0.1	2341 +/- 45	2.5 +/- 0.1
w/gSDE-64	2970 +/- 132	3.5 +/- 0.1		3.5 +/- 0.1	2476 +/- 99	2.0 +/- 0.1	2324 +/- 39	2.3 +/- 0.1
w/gSDE-episodic	2741 +/- 115	3.1 +/- 0.2		2.6 +/- 0.1	2503 +/- 80	1.8 +/- 0.1	2267 +/- 34	2.2 +/- 0.1

Return and Continuity cost results for SAC with type of exploration strategies (1M step)



Smoothness vs performance


Experiment results (II)

Comparison with SDE and gSDE


- 앞서 언급한 continuous control 문제에서, original SDE에 비해 gSDE가 더 좋은 성능을 보인다는 것을 확인
- Sampling interval에 따른 gSDE의 성능을 환경과 알고리즘을 고정한채로 비교 분석 수행
 - SAC의 경우 크게 상관 없었으며, PPO의 경우, sampling frequency를 per 4, 8 step으로 설정할 경우 성능이 가장 좋

Applying gSDE in real robot system

 SAC + gSDE를 직접 적용한 결과가 vanilla SAC에 low-pass filter를 적용한 결과보다 더욱 안전한(연속적인) 행동을 고르는 것을 실험으로 확인



(a) Exploration function input



(b) Sampling interval (PPO on WALKER2D)



(a) Tendon-driven elastic continuum neck in a hu- (b) Model-Based controller vs RL controller on the real manoid robot



Implementation for gSDE

Environment setting

Environment

- LunarLanderContinuous-v2
 - Well-known environment for continuous control in OpenAl's Gym library(Box2D problem)
- MDP parameters
 - StateAction
 - (8,)


(2,) Main engine(-1~1), direction engine(-1~1)

- Reward
 - Arrival with near-zero speed, +100~140
 - Landing with rocket leg, respectively + 10
 - Landing +100, Crash landing +100
 - Fuel consumption penalty, -0.3 per frame, (infinite fuel)

Algorithm(with Tensorflow 2)

- TD3(Twin-Delayed Deep Deterministic policy gradient), PER(Prioritized Experience Replay)
 - TD3 + gaussian noise(decaying std, initial std = 0.2, noise clipping value = 0.5)
 - TD3 + gSDE(episode, every 16 step, every 8 step)

 $https://gym.openai.com/envs/LunarLanderContinuous-v2/\\https://towardsdatascience.com/solving-lunar-lander-openaigym-reinforcement-learning-785675066197$




https://arxiv.org/pdf/1802.09477.pdf https://arxiv.org/abs/1511.05952

Result analysis

LunarLanderContinuous-v2

- Comparison with Vanilla TD3(TD3_None), TD3_gSDE(8, 16, 32, 64, Episode)
 - Figure 1 shows that TD3_gSDE is better stability than Vanilla TD3
 - gSDE 알고리즘들의 경우, 충돌이 덜 일어나기 때문에 score 그래프가 안정적으로 우 상향
 - Figure 2 shows that TD3_gSDE is better safety than Vanilla TD3 (crash landing less occurred than Vanilla TD3)



Thank you!

Q&A